




《实用Python编程》

第8讲：数据处理与分析-B


实用Python编程 教研组

提纲



Pandas简介

- Pandas是面向表格化数据处理与分析的第三方库
 - 官网 <https://pandas.pydata.org/>
 - 数据类型: Series (一维) 与DataFrame (二维)
 - 典型任务: 读取与输出、清洗、筛选、排序、聚合与分组、合并与连接
 - 安装指令: `pip install pandas`
 - 导入方式: `import pandas as pd`





读取表格化文件

- 表格作为一种二维结构化数据，其存储格式可以是
 - 文本文件类型（.txt/.csv/.json）
 - 二进制文件（.xlsx）

学生记录数据 students.csv/.json/.xlsx (3.2节)

张伟,男,1999-05-12,2018010101,计算机学院,2018,江苏省南京市,3.6,142
李静,女,2000-08-23,2019020203,经济学院,2019,浙江省杭州市,3.8,126
王明,男,2001-02-14,2020030305,外国语学院,2020,广东省广州市,3.2,108
...
高思琪,女,2001-09-15,2020181835,数学学院,2020,贵州省贵阳市,3.2,100
梁家辉,男,1999-03-27,2018191937,物理学院,2018,甘肃省兰州市,3.6,144
谢欣怡,女,2000-11-09,2019202039,化学学院,2019,吉林省长春市,3.7,138

读取表格化文件

- 在调用read_xxx函数时，需根据当前数据情况指定合适参数

表 4.3: Pandas 读取结构化数据文件的函数。工具包以import pandas as pd的方式导入

文件类型	函数	调用示例
TXT / CSV	read_csv	df=pd.read_csv("students.csv",sep=",")
JSON	read_json	df=pd.read_json("students.json"),orient='records')
Excel	read_excel	df=pd.read_excel("students.xlsx",sheet_name='Sheet1')

- read_csv默认文本文件第一行为表头（即列名）
 - 读取不含表头的文件时，需指定参数header为None

张伟,男,1999-05-12,2018010101,计算机学院,2018,江苏省南京市,3.6,142
李静,女,2000-08-23,2019020203,经济学院,2019,浙江省杭州市,3.8,126
...



```
df = pd.read_csv("students.csv", header=None)
df
```

	0	1	2	3	4	5	6	7	8
0	张伟	男	1999-05-12	2018010101	计算机学院	2018	江苏省南京市	3.6	142
1	李静	女	2000-08-23	2019020203	经济学院	2019	浙江省杭州市	3.8	126



读取表格化文件

- 可通过参数`names`手动指定列名

```
: 1 df = pd.read_csv("students.csv", header=None,  
2                   names="姓名,性别,出生日期,学号,所属学院,入学年份,籍贯,GPA,总学分".split(','))  
3 df.head()
```

	姓名	性别	出生日期	学号	所属学院	入学年份	籍贯	GPA	总学分
0	张伟	男	1999-05-12	2018010101	计算机学院	2018	江苏省南京市	3.6	142
1	李静	女	2000-08-23	2019020203	经济学院	2019	浙江省杭州市	3.8	126
2	王明	男	2001-02-14	2020030305	外国语学院	2020	广东省广州市	3.2	108
3	刘芳	女	1999-11-05	2018040407	法学院	2018	湖北省武汉市	3.7	156
4	陈浩	男	2000-07-19	2019050509	医学院	2019	四川省成都市	3.9	132

关键数据类型

- Series (序列) : 带标签的一维数组
- DataFrame (数据帧) : 带标签的二维数组

	姓名	性别	出生日期	学号	所属学院	入学年份	籍贯	GPA	总学分
0	张伟	男	1999-05-12	2018010101	计算机学院	2018	江苏省南京市	3.6	142
1	李静	女	2000-08-23	2019020203	经济学院	2019	浙江省杭州市	3.8	126
2	王明	男	2001-02-14	2020030305	外国语学院	2020	广东省广州市	3.2	108
3	刘芳	女	1999-11-05	2018040407	法学院	2018	湖北省武汉市	3.7	156
4	陈浩	男	2000-07-19	2019050509	医学院	2019	四川省成都市	3.9	132

Diagram illustrating the relationship between DataFrame and Series:

- The entire table is labeled as a **DataFrame** (indicated by a blue box).
- The **入学年份** (Enrollment Year) column is highlighted as a **Series** (indicated by a red box).



Series: 带标签的一维数组

- 组成: 索引 (index) + 值 (values)

- 创建一个Series对象


- 列表初始化 `pd.Series([671, 685, 676])`
- 数组初始化 `pd.Series(np.array([671, 685, 676]))`
- 字典初始化 (以字典的key为标签)

`pd.Series({'外国语言文学类':671,'金融学类':685,'经济学':676})`


- 也可通过index参数显式指定标签

`pd.Series([671, 685, 676],`

`index={'外国语言文学类', '金融学类', '经济学类'})`



0	671
1	685
2	676
dtype: int64	



外国语言文学类	671
金融学类	685
经济学类	676
dtype: int64	



Series中的数据

- 属性

- `s.values` #返回值列表
- `s.index` #返回索引列表

- 数据索引

- `s.iloc[0]` #按位置索引
- `s.loc['经济学']` #按标签索引
- `s.loc[['经济学', '金融学类']]` #多标签索引

```
1 s = pd.Series({'外国语言文学类':671, '金融学类':685, '经济学':676})
2 print(s.index)
3 print(s.values)
4 print('-'*20)
5 print(s.loc['经济学'])
6 print('-'*20)
7 print(s.loc[['金融学类', '经济学']])
```

```
Index(['外国语言文学类', '金融学类', '经济学'], dtype='object')
[671 685 676]
```

```
-----
676
```

```
-----
金融学类    685
经济学      676
dtype: int64
```

Series数据处理

- 数据画像：Series对象自带的describe方法

```
1 d = s2.describe()  
2 print(d['count'], d['mean'], d['min'], d['max']) #
```

数值型对象



15.0 672.2 642.0 686.0

```
3 t = pd.Series(['t1', 't1', 't1', 't2', 't3', 't3'])  
4 d = t.describe()  
5 print(d)
```

非数值型对象



count	6
unique	3
top	t1
freq	3
dtype:	object



Series数据处理

- 基于布尔索引的数据筛选

s2

外国语言文学类	671
金融学类	685
经济学类	676
法学	686
工商管理类	672
社会科学试验班（大数据技术与农林经管双主学位项目）	672
社会科学试验班（应用经济与农村发展管理双主学位项目）	672
统计学类	678
人工智能（拔尖班）	679
计算机类	674
计算机类（图灵实验班）	680
数学类（英才班）	672
应用心理学	671
金融学（中外合作办学）	653
人力资源管理（中外合作办学）	642

哪些专业的投档线高于平均水平?

```
d = s2.describe()
s2[s2>d['mean']]
```

金融学类	685
经济学类	676
法学	686
统计学类	678
人工智能（拔尖班）	679
计算机类	674
计算机类（图灵实验班）	680

DataFrame: 带标签的二维数组

- DataFrame类似一张Excel表格，也可看作多个Series按列组成
 - 在创建对象时，可通过index和columns指定表格的行索引和列名

```
1 dates = pd.date_range("20200901", periods=3)
2 data = [[12, 20, "晴"], [9, 18, "小雨"], [12, 23, "多云"]]
3 df = pd.DataFrame(data, index=dates, columns=["low-temp", "high-temp",
4         "weather"])
5 df
```


使用index
指定行索引

使用columns
指定列索引

	low-temp	high-temp	weather
2020-09-01	12	20	晴
2020-09-02	9	18	小雨
2020-09-03	12	23	多云

DataFrame表格操作

- 查看与选择





DataFrame表格操作

• 添加与删除数据

```
2 df.loc["2020-09-04"] = [10, 22, "小雨"]
3 df.loc["2020-09-05"] = [10, 24, np.nan] # np.nan表示缺失值
4 # 连续添加记录
5 for i in range(5):
6     df.loc[len(df)] = [11, 25, "阴"]
7 # 添加一列
8 df['温差'] = df['high-temp'] - df['low-temp']
9 # 原地删除存在缺失值的记录 (对应2020-09-05索引的行)
10 df.dropna(inplace=True)
11 # 原地删除新增加的列
12 df.drop(columns=['温差'], inplace=True)
13 # 原地删除重复记录
14 df.drop_duplicates(inplace=True)
15 # 原地删除最后一行
16 df.drop(df.index[-1], inplace=True)
```

	low-temp	high-temp	weather
2020-09-01	12.0	20.0	晴
2020-09-02	9.0	18.0	小雨
2020-09-03	12.0	23.0	多云
2020-09-04	10.0	22.0	小雨



课堂练习-4-2-1


- 小明这一周点了4次外卖。外卖信息如下。请利用Pandas为小明做一个电子账单，算一算这周外卖总共花了多少钱。

餐厅	消费(单位:元)
麦当劳	35
沙县小吃	15
海底捞火锅	120
轻食沙拉日记	45

多表操作

- 拼接 (`pd.concat`) : 堆叠数据
 - `axis`: 0表示纵向拼接, 1表示横向拼接
 - `Ignore_index`: `False`表示保留行标签, `True`表示舍弃原标签, 默认为`False`
- 合并 (`pd.merge`) : 补充字段
 - `on`: 用于连接两个表的字段 (键)

横向拼接默认两张表的记录 (行) 一一对应。
当前例子 (df1和df3) 不满足该设定。





多表操作

- 对多张表格进行数据汇总，以便观察特定指标变化情况

中国人民大学北京录取分数线

2020

专业名称	最高分	最低分
财政学类	675.0	674.0
法学	684.0	682.0
工商管理类	681.0	673.0
国际政治	677.0	672.0
金融学类	686.0	676.0
经济学类	687.0	674.0
理科试验班	683.0	675.0
人力资源管理	677.0	671.0
社会科学试验班（管理学科类）	674.0	671.0
社会学类	680.0	673.0
新闻传播学类	683.0	675.0
马克思主义理论类	671.0	670.0
外国语言文学类	674.0	669.0
法语（中外合作办学）	647.0	645.0
国民经济管理（中外合作办学）	640.0	639.0
金融学（中外合作办学）	652.0	640.0
数学与应用数学（中外合作办学）	660.0	645.0
绘画（加权成绩）	614.75	581.25
设计学类（加权成绩）	623.2	602.6
美术学	627.0	571.0

2021

专业名称	最高分	最低分
财政学类	671.0	670.0
法学	678.0	674.0
工商管理类	675.0	668.0
国际政治	672.0	666.0
金融学类	678.0	672.0
经济学类	676.0	667.0
理科试验班	679.0	667.0
理科试验班（基础学科类）	676.0	667.0
人力资源管理	668.0	666.0
人文科学试验班	677.0	670.0
社会科学试验班（管理学科类）	670.0	666.0
社会学类	670.0	666.0
新闻传播学类	674.0	667.0
法语（中外合作办学）	633.0	629.0
国民经济管理（中外合作办学）	638.0	631.0
金融学（中外合作办学）	650.0	632.0
人力资源管理（中外合作办学）	632.0	630.0
数学与应用数学（中外合作办学）	649.0	639.0
马克思主义理论	667.0	667.0
外国语言文学类	665.0	657.0
中国共产党历史	666.0	666.0
绘画（加权成绩）	615.75	594.5
设计学类（加权成绩）	606.4	600.8
美术学	603.0	583.0

2022

专业名称	最高分	最低分
金融学类	686.0	679.0
法学	682.0	678.0
新闻传播学类	682.0	674.0
工商管理类	682.0	673.0
经济学类	681.0	674.0
财政学类	680.0	676.0
国际政治	677.0	670.0
社会学类	674.0	670.0
人力资源管理	672.0	670.0
人文科学试验班	678.0	671.0
社会科学试验班（管理学科类）	672.0	670.0
理科试验班类	686.0	675.0
理科试验班（基础学科类）	675.0	674.0
马克思主义理论	681.0	681.0
中国共产党历史	676.0	676.0
外国语言文学类	672.0	669.0
金融学（中外合作办学）	665.0	644.0
数学与应用数学（中外合作办学）	652.0	645.0
传播学（中外合作办学，国际新闻传播方向）	646.0	646.0
国民经济管理（中外合作办学）	643.0	643.0
人力资源管理（中外合作办学）	643.0	641.0
法语（中外合作办学）	642.0	642.0
绘画（加权成绩）	653.8	584.8
美术学	628.0	578.0
设计学类（加权成绩）	628.8	609.4

2023

专业名称	最高分	最低分
马克思主义理论	669	666
中国共产党历史	665	665
外国语言文学类	666	663
金融学类	683	675
经济学类	677	673
法学	682	678
财政学类	674	672
财政学（财政学与数学双主学位项目）	673	673
工商管理类	680	669
工商管理类（数科与营销管理双主学位项目）	672	672
工商管理（中英美三学位管理本科项目）	676	671
人文科学试验班	677	672
政治学、经济学与哲学（PPE实验班）	679	678
新闻传播学类	677	671
新闻传播学类（国际新闻全英文主辅修实验班）	674	674
社会科学试验班（管理学科类）	672	670
社会学类	673	670
社会学类（社会经济或社会历史双主学位项目）	677	674
社会学类（社会学与信管双主学位项目）	673	673
人力资源管理（经管试验班）	674	670
国际政治	679	671
统计学类	679	676
人工智能（强实验）	683	677
计算机类	675	675
计算机类（图灵实验班）	679	677
数学类（英才班）	676	675
数学类（金融学与管理双主学位项目）	683	683
理科试验班类（物理实验班）	676	675
法语（中外合作办学）	645	643
传播学（中外合作办学，国际新闻传播方向）	650	648
国民经济管理（中外合作办学）	650	649
金融学（中外合作办学）	658	650
人力资源管理（中外合作办学）	649	647
数学与应用数学（中外合作办学）	666	655



	专业名称	2020	2021	2022	2023
0	法学	682.0	674.0	678.0	678
1	金融学类	676.0	672.0	679.0	675
2	经济学类	674.0	667.0	674.0	673
3	财政学类	674.0	670.0	676.0	672
4	新闻传播学类	675.0	667.0	674.0	671
5	国际政治	672.0	666.0	670.0	671
6	社会学类	673.0	666.0	670.0	670
7	工商管理类	673.0	668.0	673.0	669
8	外国语言文学类	669.0	657.0	669.0	663

数据：pybook-data/ruc_data



多表操作

- 对多张表格进行数据汇总，以便观察特定指标变化情况

```
1 # Step 1. 读取每年的录取分数表
2 years = [2020, 2021, 2022, 2023]
3 dfs = {}
4 for year in years:
5     csv_file = f'pybook-data/ruc_data/北京市/{year}.csv'
6     dfs[year] = pd.read_csv(csv_file)
7
8 # Step 2. 按专业合并最低分
9 columns = ['专业名称', '最低分']
10 merged_bj = dfs[years[0]][columns].rename(columns={'最低分': years[0]})
11 for year in years[1:]:
12     sub_table = dfs[year][columns].rename(columns={'最低分': year})
13     merged_bj = pd.merge(merged_bj, sub_table, on='专业名称')
14
15 # Step 3. 对各专业按照分数由新到旧、由高到低排序
16 merged_bj.sort_values(years[::-1], ascending=[False]*len(years), ignore_index=True, inplace=True)
```

	专业名称	2020	2021	2022	2023
0	财政学类	674.0	670.0	676.0	672
1	法学	682.0	674.0	678.0	678
2	工商管理类	673.0	668.0	673.0	669
3	国际政治	672.0	666.0	670.0	671
4	金融学类	676.0	672.0	679.0	675
5	经济学类	674.0	667.0	674.0	673
6	社会学类	673.0	666.0	670.0	670
7	新闻传播学类	675.0	667.0	674.0	671
8	外国语言文学类	669.0	657.0	669.0	663



	专业名称	2020	2021	2022	2023
0	法学	682.0	674.0	678.0	678
1	金融学类	676.0	672.0	679.0	675
2	经济学类	674.0	667.0	674.0	673
3	财政学类	674.0	670.0	676.0	672
4	新闻传播学类	675.0	667.0	674.0	671
5	国际政治	672.0	666.0	670.0	671
6	社会学类	673.0	666.0	670.0	670
7	工商管理类	673.0	668.0	673.0	669
8	外国语言文学类	669.0	657.0	669.0	663

先按2023年排，
同分数时再看2022年

表格数据批处理

- 以批处理方式计算各专业相比当年平均分的偏差
 - 先按列算均值，获得当年平均分
 - 再通过数据广播（broadcasting），让每一列自动减去该列对应的平均分

```

1 # Step 1. 按列取平均 (跳过第1列"专业名称")
2 mean_s = merged_bj.iloc[:, 1:].mean()
3 # Step 2. 计算偏差
4 diff = merged_bj.iloc[:, 1:].subtract(mean_s)
5 # Step 3. 观察结果
6 out = pd.concat([merged_bj[['专业名称']], diff.add_suffix('_偏差')], axis=1)
    
```

diff

	2020	2021	2022	2023
0	-0.222222	2.555556	2.333333	0.666667
1	7.777778	6.555556	4.333333	6.666667
2	-1.222222	0.555556	-0.666667	-2.333333
3	-2.222222	-1.444444	-3.666667	-0.333333
4	1.777778	4.555556	5.333333	3.666667
5	-0.222222	-0.444444	0.333333	1.666667
6	-1.222222	-1.444444	-3.666667	-1.333333
7	0.777778	-0.444444	0.333333	-0.333333
8	-5.222222	-10.444444	-4.666667	-8.333333



out

	专业名称	2020_偏差	2021_偏差	2022_偏差	2023_偏差
0	财政学类	-0.222222	2.555556	2.333333	0.666667
1	法学	7.777778	6.555556	4.333333	6.666667
2	工商管理类	-1.222222	0.555556	-0.666667	-2.333333
3	国际政治	-2.222222	-1.444444	-3.666667	-0.333333
4	金融学类	1.777778	4.555556	5.333333	3.666667
5	经济学类	-0.222222	-0.444444	0.333333	1.666667
6	社会学类	-1.222222	-1.444444	-3.666667	-1.333333
7	新闻传播学类	0.777778	-0.444444	0.333333	-0.333333
8	外国语言文学类	-5.222222	-10.444444	-4.666667	-8.333333



表格数据批处理

- lambda操作 (2.4.3节)

将分数转为百分制

```
1 rescaled = merged_bj.iloc[:,1:].apply(lambda x:x/750*100) #跳过第1列 (专业名称)
2 rescaled = pd.concat([merged_bj.iloc[:,0], rescaled], axis=1) #拼接第1列与转换后的分数列, 形成完整表格
3 rescaled
```

	专业名称	2020	2021	2022	2023
0	财政学类	89.866667	89.333333	90.133333	89.600000
1	法学	90.933333	89.866667	90.400000	90.400000
2	工商管理类	89.733333	89.066667	89.733333	89.200000
3	国际政治	89.600000	88.800000	89.333333	89.466667
4	金融学类	90.133333	89.600000	90.533333	90.000000
5	经济学类	89.866667	88.933333	89.866667	89.733333
6	社会学类	89.733333	88.800000	89.333333	89.333333
7	新闻传播学类	90.000000	88.933333	89.866667	89.466667
8	外国语言文学类	89.200000	87.600000	89.200000	88.400000



- 数据经常需要重组以适应不同的任务需求

数据聚合

数据重组

(c)

数据分析

任务：分析人大各专业在各省的填报热度

数据统计

(d)

图 4.6: Pandas 表格数据汇聚、透视重组与统计分析

表格重组

- 第1步. 数据聚合
 - 读取并拼接各省各专业分数线，产生一个包含500多条记录的长表

```
1 from pathlib import Path
2
3 # Step 1. 获得所有省份2023年的CSV文件列表
4 root_path = Path('pybook-data/ruc_data')
5 csv_files = list(root_path.rglob('2023.csv'))
6 csv_files = [str(x) for x in csv_files]
7
8 # Step 2. 读入各省的招生数据表并清洗数据
9 tables = [None]*len(csv_files)
10 for i, csv_fname in enumerate(csv_files):
11     prov = csv_fname.split('/')[1]
12     df = pd.read_csv(csv_fname).rename(columns={'理工/物理类 最低': '最低分'})
13     sub_table = df[['专业名称', '最低分']].drop_duplicates() # 去掉可能存在的重复记录
14     sub_table.insert(0, '省份', [prov]*len(sub_table))
15     tables[i] = sub_table.dropna() # 去掉没有理工类的记录
16
17 # Step 3. 将各省各专业投档分纵向拼接成一个长表
18 long_table = pd.concat(tables, ignore_index=True)
19 print('记录数:', len(long_table)) # 记录数: 537
```



	省份	专业名称	最低分
0	安徽省	外国语言文学类	664.0
1	安徽省	金融学类	673.0
2	安徽省	经济学类	669.0
3	安徽省	法学	667.0
4	安徽省	工商管理类	661.0
...	...	...	...
532	广东省	数学类（英才班）	673.0
533	广东省	金融学（中外合作办学）	649.0
534	广东省	人力资源管理（中外合作办学）	644.0
535	广东省	数学与应用数学（中外合作办学）	648.0
536	广东省	国民经济管理（高校专项）	585.0

537 rows x 3 columns

表格重组

• 第2步. 数据透视

- 为了以 (省份,专业) 为组合进行分析, 需要把长表中的“专业名称”列拆开
- 通过透视操作 `pd.pivot` 将长表变为宽表

```
wide_table = long_table.pivot(index='省份',columns='专业名称',values = '最低分')
```

省份	专业名称	最低分
0 安徽省	外国语言文学类	664.0
1 安徽省	金融学类	673.0
2 安徽省	经济学类	669.0
3 安徽省	法学	667.0
4 安徽省	工商管理类	661.0
...	...	...
532 广东省	数学类 (英才班)	673.0
533 广东省	金融学 (中外合作办学)	649.0
534 广东省	人力资源管理 (中外合作办学)	644.0
535 广东省	数学与应用数学 (中外合作办学)	648.0
536 广东省	国民经济管理 (高校专项)	585.0

专业名称

中国共产党历史

人力资源管理 (中外合作办学)

人力资源管理 (经管试验班)

人力资源管理 (经管试验班) (区内)

人力资源管理 (经管试验班, 协作计划)

人力资源管理 (经管试验班, 国家专项)

人力资源管理 (经管试验班, 高校专项)

人工智能 (拔尖班)

人文科学试验班

传播学 (中外合作办学, 国际新闻传播方向)

...

计算机类

计算机类 (国家专项)

计算机类 (图灵实验班)

财政学类

财政学类 (国家专项)

财政学 (财政学双学位项目)

金融学类

金融学类 (国家专项)

金融学 (中外合作办学)

马克思主义理论

省份

上海市

云南省

内蒙古自治区

上海市	NaN	NaN	NaN	NaN	NaN	NaN	NaN	589.0	601.0	571.0	...	NaN	NaN	NaN	NaN	NaN	NaN	587.0	NaN	571.0	NaN
云南省	NaN	NaN	662.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	658.0	NaN	NaN	NaN	NaN	NaN	674.0	NaN	643.0	NaN
内蒙古自治区	NaN	NaN	NaN	NaN	NaN	NaN	NaN	638.0	NaN	NaN	...	639.0	NaN	NaN	NaN	NaN	NaN	652.0	NaN	609.0	NaN

537 rows x 3 columns



表格数据统计与分析

- 通过对宽表逐行定位最大值，就可找出每个地区投档线最高的专业

```
wide_table.fillna(0, inplace=True) #先用0填充缺失值
wide_table['最高分专业'] = wide_table.idxmax(axis=1) #找出每个省（直辖市）投档线最高的专业
wide_table['最高分'] = wide_table.iloc[:, :-1].max(axis=1) #单独列出最热门专业的投档分
```

专业名称	中国历史	人力资源管理(中外合作办学)	人力资源管理(经营试验班)	人力资源管理(经营试验班)(区内)	人力资源管理(经营试验班, 协作计划)	人力资源管理(经营试验班, 国家专项)	人力资源管理(经营试验班, 高校专项)	人工智能(拔尖班)	人文科学试验班	传播学(中外合作办学, 国际新闻传播方向)	计算机类	计算机类(国家专项)	计算机类(图灵实验班)	财政学类	财政学类(国家专项)	财政学类(财政学双学位项目)	金融学类	金融学类(国家专项)	金融学类(中外合作办学)	马克思主义理论
省份																				
上海市	NaN	NaN	NaN	NaN	NaN	NaN	NaN	589.0	601.0	571.0	...	NaN	NaN	NaN	NaN	NaN	587.0	NaN	571.0	NaN
云南省	NaN	NaN	662.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	658.0	NaN	NaN	NaN	NaN	674.0	NaN	643.0	NaN
内蒙古自治区	NaN	NaN	NaN	NaN	NaN	NaN	NaN	638.0	NaN	NaN	...	639.0	NaN	NaN	NaN	NaN	652.0	NaN	609.0	NaN



专业名称	最高分专业	最高分
上海市	法学	609.0
云南省	法学	689.0
内蒙古自治区	统计学类	653.0
北京市	数学类（金融学与数学双主学位项目）	683.0
吉林省	金融学类	657.0
四川省	人工智能（拔尖班）	685.0
天津市	政治学、经济学与哲学（PPE实验班）	695.0
宁夏回族自治区	金融学类	617.0
安徽省	经济学类（国家专项）	673.0
山东省	人工智能（拔尖班）	678.0



表格数据统计与分析

• 统计各专业的填报热度

```
1 wide_table['最高分专业'].value_counts().to_frame() # 统计热门专业的省份频率
```

	count
最高分专业	
法学	10
金融学类	7
人工智能（拔尖班）	6
数学类（金融学与数学双主学位项目）	2
统计学类	1
政治学、经济学与哲学（PPE实验班）	1
经济学类（国家专项）	1
经济学类	1
社会科学试验班（管理学科类，国家专项，区外）	1

该统计仅考虑了各专业的填报频度，而未考虑其投放频度

表格数据统计与分析

- 统计各专业的投放频度，即可报考该专业的省份数

`wide_table.iloc[:, :-2] > 0`

专业名称	中国历史	人力资源管理(中外合作办学)	人力资源管理(经管试验班)	人力资源管理(经管试验班)(区内)	人力资源管理(经管试验班, 协作计划)	人力资源管理(经管试验班, 国家专项)	人力资源管理(经管试验班, 高校专项)	人工智能(拔尖班)	人文科学试验班	传播学(中外合作办学, 国际新闻传播方向)	...	计算机类	计算机类(国家专项)	计算机类(图灵实验班)	财政学类(国家专项)	财政学类(财政学与数学双学士学位项目)	金融学类(国家专项)	金融学(中外合作办学)	马克思主义理论	
省份																				
上海市	NaN	NaN	NaN	NaN	NaN	NaN	NaN	589.0	601.0	571.0	...	NaN	NaN	NaN	NaN	NaN	587.0	NaN	571.0	NaN
云南省	NaN	NaN	662.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	658.0	NaN	NaN	NaN	NaN	674.0	NaN	643.0	NaN
内蒙古自治区	NaN	NaN	NaN	NaN	NaN	NaN	NaN	638.0	NaN	NaN	...	639.0	NaN	NaN	NaN	NaN	652.0	NaN	609.0	NaN



专业名称	中国历史	人力资源管理(中外合作办学)	人力资源管理(经管试验班)	人力资源管理(经管试验班, 区内)	人力资源管理(经管试验班, 协作计划)	人力资源管理(经管试验班, 国家专项)	人力资源管理(经管试验班, 国家专项)	人工智能(拔尖班)	人文科学试验班	传播学(中外合作办学, 国际新闻传播方向)	...	计算机类	计算机类(国家专项)	计算机类(国家专项)	财政学类	财政学类(国家专项)	财政学类(国家专项)	金融学类	金融学类(国家专项)	金融学类(国家专项)	马克思主义理论
省份																					
上海市	False	False	False	False	False	False	False	True	True	True	...	False	False	False	False	False	False	True	False	True	False
云南	False	False	True	False	False	False	False	False	False	False	...	True	False	False	False	False	False	True	False	True	False



列和即为每个专业的投放频度

`s2 = (wide_table.iloc[:, :-2] > 0).sum()`



表格数据统计与分析

- 以投放频度为分母对热度进行校正

```
s1 = wide_table['最高分专业'].value_counts()  
s2 = (wide_table.iloc[:, :-2] > 0).sum()  
s1.name = '热度'  
s2.name = '地区频度'
```

s1		热度
最高分专业		
法学	10	
金融学类	7	
人工智能（拔尖班）	6	
数学类（金融学与数学双主学位项目）	2	
统计学类	1	
政治学、经济学与哲学（PPE实验班）	1	
经济学类（国家专项）	1	
经济学类	1	
社会科学试验班（管理学科类，国家专项，区外）	1	

s2		地区频度
专业名称		
中国共产党历史	3	
人力资源管理（中外合作办学）	9	
人力资源管理（经管试验班）	9	
人力资源管理（经管试验班）（区内）	1	
人力资源管理（经管试验班，协作计划）	1	
...	...	
财政学（财政学与数学双主学位项目）	7	
金融学类	29	
金融学类（国家专项）	2	
金融学（中外合作办学）	23	
马克思主义理论	3	

两个Series对象合并时，
相同索引的行会合并到同一行，
缺失值用 NaN 填充

```
overview = pd.concat([s1, s2], axis=1).dropna()  
overview['占比'] = overview[s1.name] / overview[s2.name]  
overview.sort_values(by='占比', ascending=False)
```

overview	热度	地区频度	占比
社会科学试验班（管理学科类，国家专项，区外）	1.0	1	1.000000
经济学类（国家专项）	1.0	2	0.500000
法学	10.0	24	0.416667
数学类（金融学与数学双主学位项目）	2.0	6	0.333333
人工智能（拔尖班）	6.0	23	0.260870
金融学类	7.0	29	0.241379
政治学、经济学与哲学（PPE实验班）	1.0	6	0.166667
经济学类	1.0	27	0.037037
统计学类	1.0	28	0.035714

表格数据统计与分析

- “占比”计算的可靠性问题
- 解决方案：对投放频度设置一个准入门槛，仅对超过该门槛的专业进行热度排序

```
1 bar = int(len(wide_table)*0.3) # 只考虑在全国30%以上省份投放的专业
2 overview = overview[ overview['地区频度']>=bar ]
3 overview.sort_values(by='占比', ascending=False)
```

	热度	地区频度	占比
社会科学试验班（管理学科类，国家专项，区外）	1.0	1	1.000000
经济学类（国家专项）	1.0	2	0.500000
法学	10.0	24	0.416667
数学类（金融学与数学双主学位项目）	2.0	6	0.333333
人工智能（拔尖班）	6.0	23	0.260870
金融学类	7.0	29	0.241379
政治学、经济学与哲学（PPE实验班）	1.0	6	0.166667
经济学类	1.0	27	0.037037
统计学类	1.0	28	0.035714



	热度	地区频度	占比
法学	10.0	24	0.416667
人工智能(拔尖班)	6.0	23	0.260870
金融学类	7.0	29	0.241379
经济学类	1.0	27	0.037037
统计学类	1.0	28	0.035714

工具不能代替我们思考与决策！



课堂练习-4-2-2

- 教务系统导出的某次考试成绩如下。请找出每科最好成绩及对应学生的姓名。

```
raw_data = {  
    "姓名": ["张三", "张三", "李四", "李四", "王五", "王五"],  
    "学科": ["语文", "数学", "语文", "数学", "语文", "数学"],  
    "成绩": [85, 92, 78, 88, 90, 85]  
}  
score_table = pd.DataFrame(raw_data)
```

	姓名	学科	成绩
0	张三	语文	85
1	张三	数学	92
2	李四	语文	78
3	李四	数学	88
4	王五	语文	90
5	王五	数学	85



综合应用：高考志愿填报推荐

- 开发一个服务于北京考生的志愿填报程序
 - 根据当前名次和往年录取数据，推荐三个填报区间：冲击、稳妥、保底
- 涉及技术
 - 网上数据抓取
 - 原始数据清洗，整理为表格
 - 表格数据统计与查询



综合应用：高考志愿填报推荐

• 第1步. 抓取2024年北京高考数据（投档线、分段表）

```
1 import os
2 from p3lib.ch3 import url_to_filename, PageDownloader
3
4 data_dir = 'beijing'
5 crawler = PageDownloader(save_dir=data_dir)
6 #抓取北京市2024年本科普通批录取投档线
7 target_url = "https://gaokao.eol.cn/bei_jing/dongtai/202407/t20240720_2625168.shtml"
8 crawler.process(target_url)
9 score_file = os.path.join(data_dir, f'{url_to_filename(target_url)}.html')
10 assert(os.path.exists(score_file)) #检查目标网页是否已保存到指定路径
11 #抓取2024年北京高考分段表
12 target_url = "https://gaokao.eol.cn/bei_jing/dongtai/202406/t20240625_2619192.shtml"
13 crawler.process(target_url)
14 rank_file = os.path.join(data_dir, f'{url_to_filename(target_url)}.html')
15 assert(os.path.exists(rank_file))
```

[Status] 开始抓取 https://gaokao.eol.cn/bei_jing/dongtai/202407/t20240720_2625168.shtml

[Status] 已保存到 beijing/aHR0cHM6Ly9nYW9rYW8uZW9sLmNuL2JlaV9qaW5nL2Rvbmd0YWkvMjAyNDA3L3QyMDI0MDcyMF8yNjI1MTY4LnNodG1s.html

[Status] 页面抓取成功

[Status] 开始抓取 https://gaokao.eol.cn/bei_jing/dongtai/202406/t20240625_2619192.shtml

[Status] 已保存到 beijing/aHR0cHM6Ly9nYW9rYW8uZW9sLmNuL2JlaV9qaW5nL2Rvbmd0YWkvMjAyNDA2L3QyMDI0MDYyNV8yNjE5MTkyLnNodG1s.html

[Status] 页面抓取成功

综合应用：高考志愿填报推荐

• 第2步. 数据清洗

```
1 score_df = pd.read_html(score_file)[0]
2 score_df = score_df[1:].reset_index(drop=True) #跳过原表第一行, 并重置行索引
3 score_df.columns = ['院校代码', '院校', '专业组代码', '限制', '投档线'] #列重命名
4 score_df['投档线'] = score_df['投档线'].astype(int)
```

	0	1	2	3	4
0	院校	院校	专业组	专业组	总分
1	1021	北京大学	2	不限	700
2	1023	清华大学	2	物理	698
3	1021	北京大学	3	物理+化学	690
4	1023	清华大学	3	物理+化学	689
...	...	...	...	...	...
1254	6518	喀什大学	3	物理+化学	434
1255	6519	新疆政法学院	2	物理+化学	434
1256	6521	新疆和田学院	3	物理+化学	434
1257	6522	昌吉学院	3	物理+化学	434
1258	6523	新疆理工学院	1	物理+化学	434

1259 rows × 5 columns



	院校代码	院校	专业组代码	限制	投档线
0	1021	北京大学	2	不限	700
1	1023	清华大学	2	物理	698
2	1021	北京大学	3	物理+化学	690
3	1023	清华大学	3	物理+化学	689
4	1021	北京大学	1	不限	688
...	...	...	...	...	...
1253	6518	喀什大学	3	物理+化学	434
1254	6519	新疆政法学院	2	物理+化学	434
1255	6521	新疆和田学院	3	物理+化学	434
1256	6522	昌吉学院	3	物理+化学	434
1257	6523	新疆理工学院	1	物理+化学	434

1258 rows × 5 columns

综合应用：高考志愿填报推荐

• 第3步. 分段表清洗并规整

```
1 rank_df = pd.read_html(rank_file)[0]
2 rank_df = rank_df[1:].reset_index(drop=True)
3 rank_df.columns = ['分数', '人数', '位次']
4 rank_df.iloc[0,0] = "700" #将第一行的700-750替换为700
5 hit = rank_df['分数'].str.contains(r'本科线', na=False) #正则匹配, 查找含有'本科线'字样的行
6 cutoff = hit.idxmax() #定位本科线对应的行
7 rank_df = rank_df[:cutoff+1] # 舍弃该行之后的数据
8 rank_df['分数'] = rank_df['分数'].str.replace(r'(.*)', '', regex=True) #清除注释(特招线、本科线)
9 rank_df = rank_df.astype(int)
```

定位本科线，并舍弃
该线之后的数据

	0	1	2
0	分数	人数	累计人数
1	700-750	117	117
2	699	15	132
3	698	16	148
4	697	17	165
...	...	...	...
327	140-149	11	55876
328	130-139	15	55891
329	120-129	18	55909
330	110-119	16	55925
331	100-109	11	55936

332 rows x 3 columns



	分数	人数	位次
0	700	117	117
1	699	15	132
2	698	16	148
3	697	17	165
4	696	18	183
...	...	...	...
262	438	170	44347
263	437	156	44503
264	436	149	44652
265	435	137	44789
266	434	134	44923

267 rows x 3 columns

通过正则匹配清除个别分
数单元格中包含的注解
(特招线、本科线等)

综合应用：高考志愿填报推荐

• 第4步. 分数转位次

- 分段表提供分数到位次映射
- map方法将投档线转成对应位次

将“分数”列设置为行索引

```
1 score_rank = rank_df.set_index('分数')['位次'] # 先构造“分数->位次”的映射表
2 score_df['位次'] = score_df['投档线'].map(score_rank)
```

	院校代码	院校	专业组代码	限制	投档线	位次
0	1021	北京大学	2	不限	700	117
1	1023	清华大学	2	物理	698	148
2	1021	北京大学	3	物理+化学	690	354
3	1023	清华大学	3	物理+化学	689	384
4	1021	北京大学	1	不限	688	423
...	...	...	...	...	...	...
1253	6518	喀什大学	3	物理+化学	434	44923
1254	6519	新疆政法学院	2	物理+化学	434	44923
1255	6521	新疆和田学院	3	物理+化学	434	44923
1256	6522	昌吉学院	3	物理+化学	434	44923
1257	6523	新疆理工学院	1	物理+化学	434	44923

score_rank的数据类型是什么？



综合应用：高考志愿填报推荐

• 第5步. 基于位次的志愿推荐

```
1 n_24, n_25 = 6.72, 7.89 # 2024, 2025年北京高考人数 (单位: 万)
2 rank_25 = 16470 # 考生当前位次
3 query = int(rank_25*n_24/n_25+0.5) # 按人数比值修正位次
4 error = 0.05
5 low = int(query * (1 - error))
6 high = int(query * (1 + error))
7 hit = score_df[(score_df['位次'] >= low) & (score_df['位次'] <= high)]
8 print(f'2025年位次: {rank_25}, 对应2024年位次: {query}')
9 print(f'位次在[{low}, {high}]的专业组数: {len(hit)}')
10 """输出:
11 2025年位次: 16470, 对应2024年位次: 14028
12 位次在[13326, 14729]的专业组数: 47
13 """
14 sub = hit[hit['限制'].str.contains(r'不限') == True]
15 print(f'无限制的专业组数: {len(sub)}')
16 sub = hit[hit['限制'].str.contains(r'物理$') == True]
17 print(f'限"物理"的专业组数: {len(sub)}')
18 """输出:
19 无限制的专业组数: 10
20 限"物理"的专业组数: 7
21 """
```

通过设置查询条件
缩小推荐范围

hit: 当前位次前后5%区间的志愿

	院校代码	院校	专业组代码	限制	投档线	位次
399	1035	北京语言大学	2	物理	586	13407
400	2110	大连海事大学	4	物理	586	13407
401	3244	南京审计大学	1	不限(中外合办)	586	13407
402	4418	广东以色列理工学院	1	物理+化学(中外合办)	586	13407
403	6112	长安大学	2	物理	586	13407
404	1030	北京林业大学	1	物理+化学(中外合办)	585	13610
405	1035	北京语言大学	4	物理+化学	585	13610
406	1036	中国传媒大学	2	物理+化学(中外合办)	585	13610
407	1043	中国地质大学(北京)	3	物理+化学	585	13610
408	1049	北京工业大学	3	物理+化学	585	13610
409	1049	北京工业大学	5	物理(中外合办)	585	13610